ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT

KHOA TÀI CHÍNH – NGÂN HÀNG

ĐỒ ÁN CUỐI KỲ
KHAI THÁC DỮ LIỆU TRONG TÀI CHÍNH
(DATA MINING)

CASE 7: WHICH PROMOTION WAS THE MOST EFFECTIVE?

GVHD: NCS Phan Huy Tâm

SVTH: Võ Quốc Tiến – K234141742

LHP: 252BFF401704

TP.HCM, THÁNG 03/2026

MỤC LỤC

DANH MỤC HÌNH ẢNH **3**
I. Mô tả bài toán và dữ liệu **4**
1.1. Mô tả bài toán 4
1.2. Mô tả bộ dữ liệu 4
1.3. Vấn đề dữ liệu và hướng xử lý 4
II. Mô hình có thể sử dụng **5**
2.1. Kiểm định thống kê (ANOVA và T-test) 5
2.2. OLS Regression 5
2.3. Decision Tree Regressor 5
2.4. Các mô hình khác có thể xem xét 5
III. Phân tích khám phá dữ liệu — EDA **6**
3.1. Tổng quan thống kê mô tả 6
3.2. So sánh doanh số theo Promotion 6
3.3. Phân bố doanh số của từng Promotion 7
3.4. Ma trận doanh số: Market Size × Promotion 7
3.5. Phân tích theo Quy mô thị trường 8
3.6. Xu hướng doanh số theo tuần 9
3.7. Tương quan giữa tuổi cửa hàng và doanh số 9
IV. Điểm đặc biệt và lưu ý **10**
4.1. Vấn đề đa so sánh 10
4.2. Promotion 1 vs 3: Chênh lệch không có ý nghĩa thống kê 10
4.3. sklearn.LinearRegression không cung cấp p-value 10
4.4. Cấu trúc dữ liệu dạng Panel 10
4.5. Market Size là biến quan trọng 10
4.6. Thiếu thông tin về nội dung promotion 10
V. Thực hiện mô hình và kết quả **11**
5.1. Kiểm định ANOVA 11
5.2. T-test pairwise với Bonferroni Correction 11
5.3. OLS Regression 12
5.4. Decision Tree 13
VI. Kết luận và khuyến nghị **14**
6.1. Trả lời câu hỏi nghiên cứu 14
6.2. Khuyến nghị 14
6.3. Hạn chế và hướng nghiên cứu tiếp theo 14

DANH MỤC HÌNH ẢNH

Hình 1 - Boxplot và Bar chart so sánh doanh số theo Promotion 6

Hình 2 - Histogram phân bố doanh số của từng Promotion 7

Hình 3 - Heatmap doanh số trung bình theo 7

Hình 4 - Bar chart doanh số phân theo Quy mô thị trường và Promotion 8

Hình 5 - Phân bố mẫu và doanh số trung bình theo Market Size 8

Hình 6 - Xu hướng doanh số hàng tuần theo từng Promotion 9

Hình 7 - Scatter plot: Tuổi cửa hàng vs Doanh số 9

Hình 8 - Hệ số OLS Regression với khoảng tin cậy 95% 12

Hình 9 - Feature Importance của Decision Tree 13

Hình 10 - Cây quyết định hoàn chỉnh (max_depth=4) 13

I. Mô tả bài toán và dữ liệu

1.1. Mô tả bài toán

Một chuỗi thức ăn nhanh đang chuẩn bị tung ra sản phẩm mới và cần chọn chiến dịch marketing hiệu quả nhất trong ba phương án (Promotion 1, 2, 3). Công ty thiết kế một thí nghiệm thực địa: sản phẩm mới được triển khai tại các cửa hàng được chọn ngẫu nhiên ở nhiều thị trường, mỗi thị trường áp dụng một loại promotion khác nhau, và doanh số được ghi nhận trong 4 tuần đầu. Đây là bài toán kiểm định thí nghiệm A/B/C kết hợp phân tích hồi quy, thuộc nhóm bài toán hồi quy — dự đoán biến liên tục.

1.2. Mô tả bộ dữ liệu

Dataset gồm 548 quan sát, thu thập từ 137 cửa hàng độc lập, theo dõi trong 4 tuần. Mỗi hàng là doanh số của một cửa hàng trong một tuần.

Bảng 1. Mô tả các biến trong dataset

Biến	Kiểu	Mô tả
MarketID	Định danh	Mã thị trường
LocationID	Định danh	Mã cửa hàng duy nhất — 137 cửa hàng
AgeOfStore	Liên tục	Tuổi cửa hàng: 1–28 năm, trung bình 8.5 năm
MarketSize	Phân loại	Quy mô thị trường: Small, Medium, Large
Promotion	Phân loại	Loại chiến dịch: 1, 2 hoặc 3
week	Thời gian	Tuần quan sát: 1, 2, 3 hoặc 4
SalesInThousands	Liên tục	Biến mục tiêu: Doanh số (nghìn USD)

1.3. Vấn đề dữ liệu và hướng xử lý

Biến phân loại cần mã hóa: Promotion (1/2/3) và MarketSize (Small/Medium/Large) là biến định danh, cần chuyển thành biến giả trước khi đưa vào mô hình hồi quy. Promotion 1 và Small được chọn làm nhóm cơ sở để tránh bẫy biến giả.

Kiểu dữ liệu bool từ get_dummies: Pandas phiên bản mới trả về dtype bool thay vì int khi gọi get_dummies(). Cần thêm.astype(int) để đảm bảo numpy/sklearn xử lý đúng.

Cấu trúc dữ liệu dạng panel: Mỗi cửa hàng xuất hiện 4 lần (4 tuần) → các quan sát không hoàn toàn độc lập. Mô hình OLS cơ bản chưa kiểm soát hiệu ứng cố định theo cửa hàng. Đây là hạn chế cần lưu ý.

Biến MarketID không có giá trị phân tích: Biến này là mã nội bộ, không mang thông tin dự đoán — loại bỏ khỏi mô hình.

II. Mô hình có thể sử dụng

Bài toán có biến mục tiêu liên tục (SalesInThousands) và câu hỏi nghiên cứu tập trung vào so sánh nhóm và giải thích nhân quả, do đó các nhóm mô hình phù hợp gồm:

2.1. Kiểm định thống kê (ANOVA và T-test)

Phù hợp nhất để trả lời trực tiếp câu hỏi: "Có sự khác biệt có ý nghĩa thống kê giữa các promotion không?". ANOVA kiểm tra đồng thời tất cả các nhóm; T-test pairwise với Bonferroni Correction xác định cụ thể cặp nào khác nhau.

2.2. OLS Regression

Cho phép định lượng tác động riêng lẻ của từng biến khi kiểm soát các yếu tố khác (Market Size, AgeOfStore). Đặc biệt hữu ích để trả lời: "Promotion X làm tăng/giảm doanh số bao nhiêu so với Promotion 1, khi giữ nguyên quy mô thị trường?"

2.3. Decision Tree Regressor

Là mô hình phi tham số, nắm bắt được quan hệ phi tuyến và tương tác giữa các biến. Feature Importance từ Decision Tree giúp xác định biến nào ảnh hưởng nhất mà không cần giả định phân phối, không cần mã hóa biến giả.

2.4. Các mô hình khác có thể xem xét

Random Forest / Gradient Boosting: Nâng cao hơn Decision Tree, giảm overfitting, cho Feature Importance ổn định hơn.

Mixed-Effects Model: Xử lý đúng cấu trúc panel data — kiểm soát hiệu ứng cố định theo LocationID.

Bayesian ANOVA: Cung cấp ước lượng xác suất thay vì chỉ p-value, phù hợp khi cỡ mẫu nhỏ.

Bảng 2. So sánh các mô hình phù hợp với bài toán

Tiêu chí	**ANOVA/T-test**	**OLS Regression**	**Decision Tree**
Mục tiêu chính	So sánh nhóm	Định lượng tác động	Phân khúc, dự báo
Có p-value?	Có	Có	Không
Xử lý tương tác	Không	Hạn chế	Tốt
R^2 đạt được	N/A	0.5820	0.6410
Phù hợp bài toán?	Rất phù hợp	Rất phù hợp	Phù hợp

III. Phân tích khám phá dữ liệu — EDA

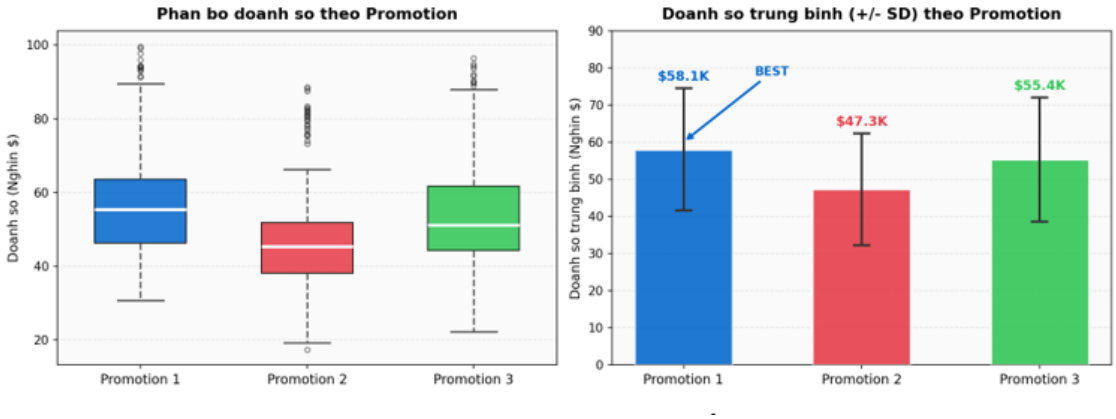
3.1. Tổng quan thống kê mô tả

Bảng 3. Thống kê mô tả doanh số theo Promotion

Promotion	N	Mean	Std	Min	Max	CV%
Promotion 1	172	58.1K	16.55K	17.34K	99.65K	28.5%
Promotion 2	188	47.3K	15.11K	17.44K	87.97K	31.9%
Promotion 3	188	55.34K	16.77K	17.58K	91.49K	30.3%
Tổng thể	548	53.47K	16.76K	17.34K	99.65K	31.4%

Ghi chú: CV% = Coefficient of Variation = Std/Mean × 100%

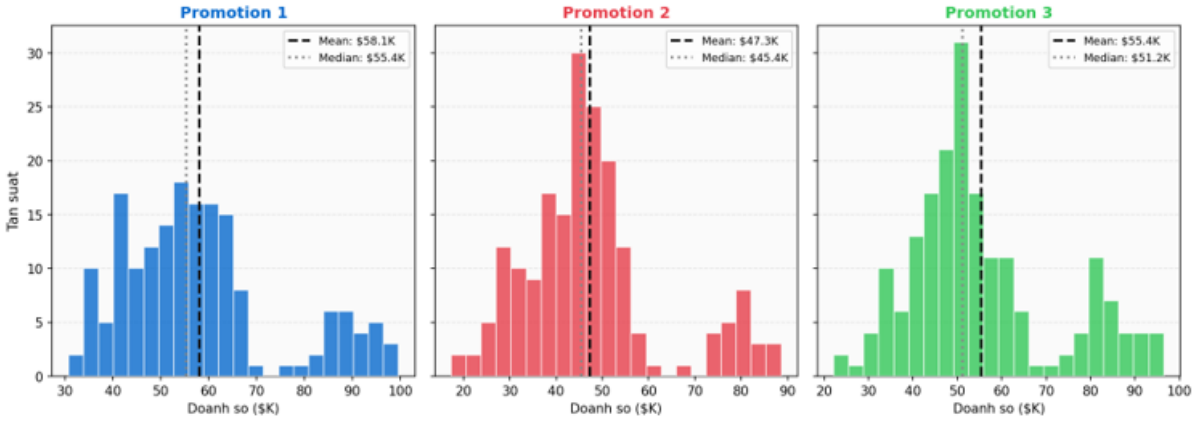
3.2. So sánh doanh số theo Promotion



Hình 1 - Boxplot và Bar chart so sánh doanh số theo Promotion

Promotion 1 có doanh số trung bình cao nhất (58.10K), Promotion 3 đứng thứ hai (55.4K) và Promotion 2 thấp nhất (47.3K). Boxplot cho thấy cả ba nhóm có phân phối khá tương tự về độ rộng, điều này hỗ trợ giả định đồng nhất phương sai cần thiết cho ANOVA.

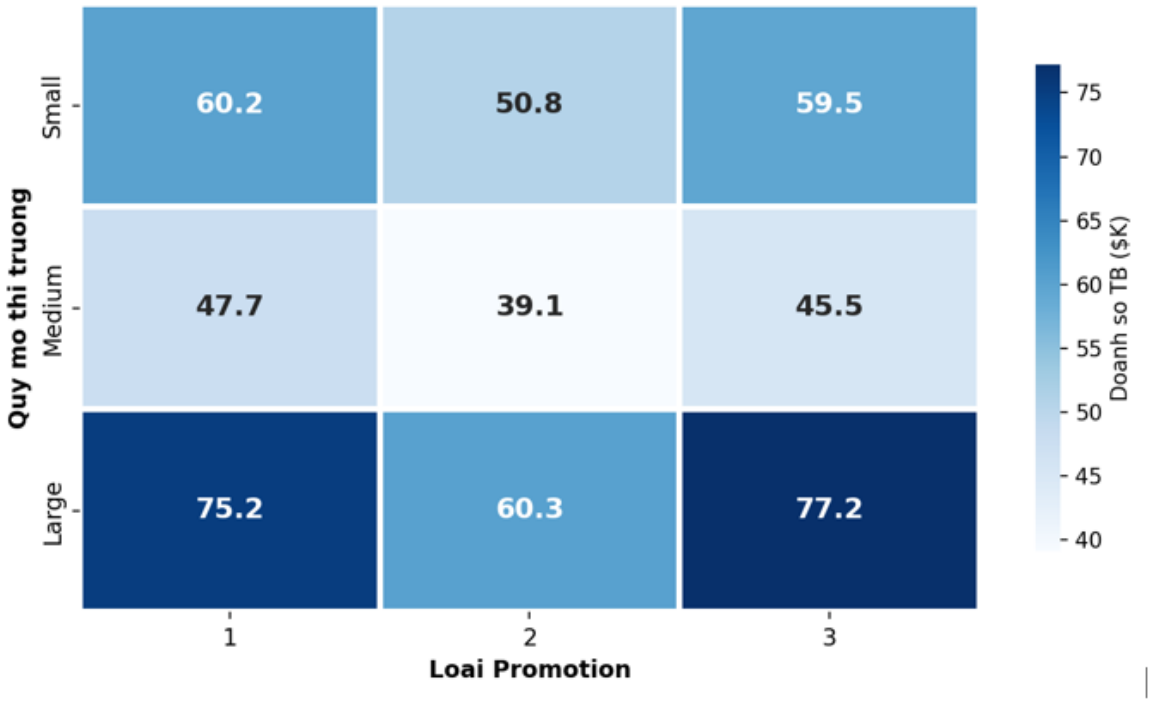
3.3. Phân bố doanh số của từng Promotion



Hình 2 - Histogram phân bố doanh số của từng Promotion

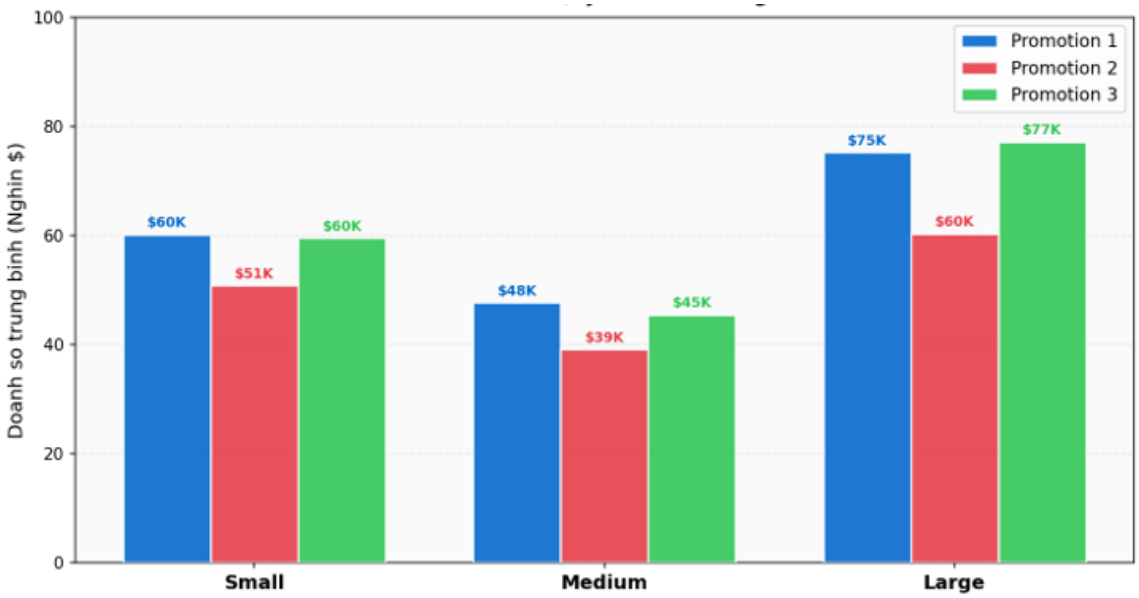
Cả ba promotion đều có phân phối gần đối xứng, không có hiện tượng lệch phân phối nghiêm trọng. Đây là điều kiện thuận lợi để áp dụng các kiểm định như ANOVA và T-test.

3.4. Ma trận doanh số: Market Size × Promotion



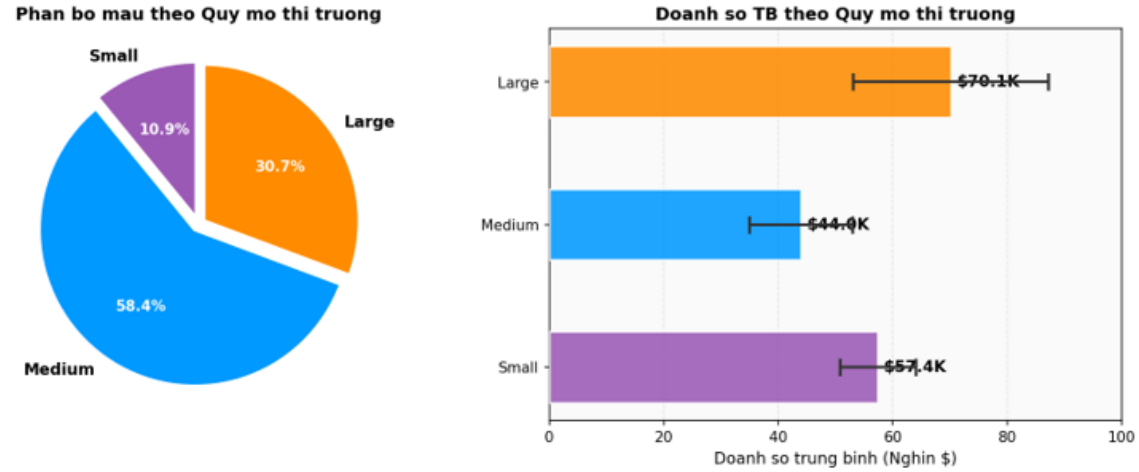
Hình 3 - Heatmap doanh số trung bình theo

Quan sát đáng chú ý: Tại thị trường Large, Promotion 3 (77.2K) thực tế cao hơn Promotion 1 (75.2K) một chút, nhưng cần kiểm định thống kê để xác nhận. Market Size rõ ràng có tác động lớn: Large Market mang lại doanh số gấp đôi Medium Market.



Hình 4 - Bar chart doanh số phân theo Quy mô thị trường và Promotion

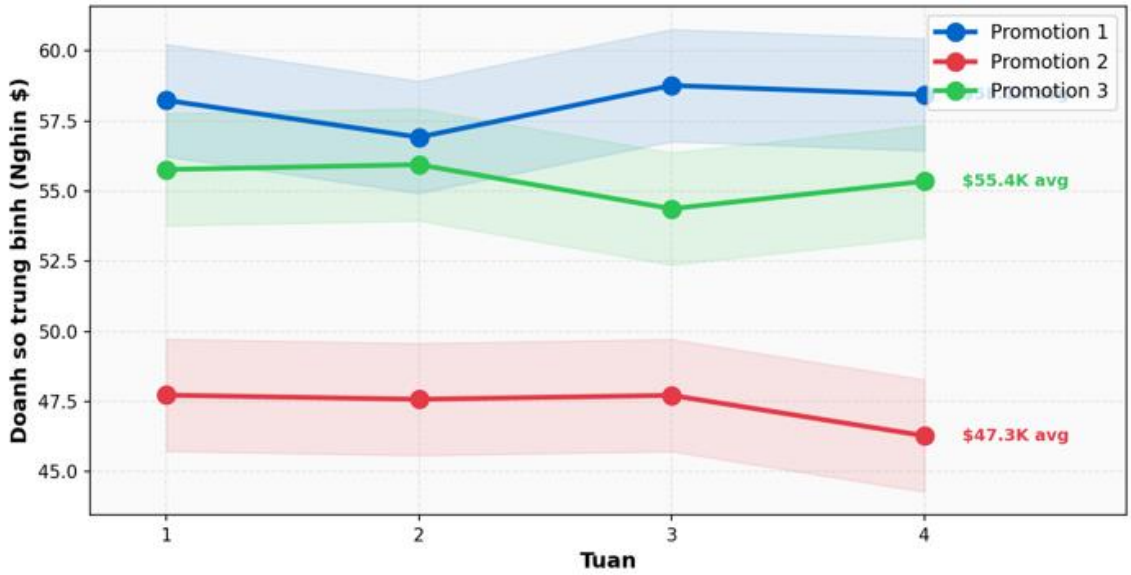
3.5. Phân tích theo Quy mô thị trường



Hình 5 - Phân bố mẫu và doanh số trung bình theo Market Size

Thị trường Large đạt doanh số trung bình 70.1K, vượt xa Medium (44K) và Small (57.4K). Phân bố mẫu chủ yếu là Medium (58.4%), đảm bảo kết quả hồi quy cho phân khúc này đáng tin cậy.

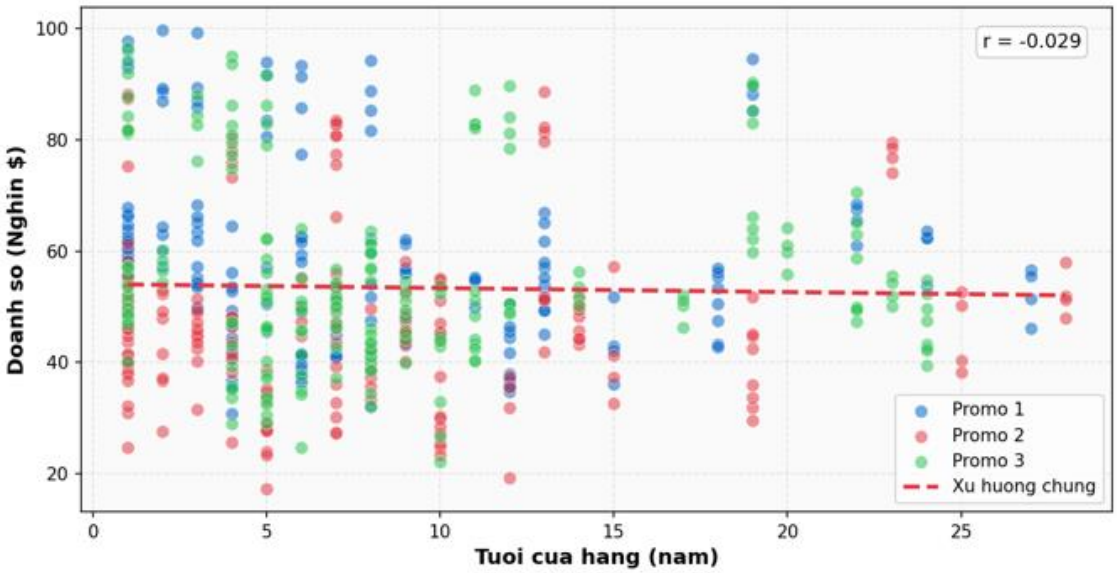
3.6. Xu hướng doanh số theo tuần



Hình 6 - Xu hướng doanh số hàng tuần theo từng Promotion

Doanh số của cả ba promotion duy trì ổn định qua 4 tuần (hệ số tương quan giữa tuần và doanh số r = -0.011, gần bằng 0). Điều này cho thấy: (1) không có hiệu ứng "mới lạ" giảm dần, (2) kết quả 4 tuần có thể đại diện cho hiệu quả dài hạn của promotion.

3.7. Tương quan giữa tuổi cửa hàng và doanh số



Hình 7 - Scatter plot: Tuổi cửa hàng vs Doanh số

Scatter plot và hệ số tương quan Pearson gần 0 cho thấy tuổi cửa hàng không có mối quan hệ tuyến tính đáng kể với doanh số. Kết quả này sẽ được xác nhận lại bởi OLS Regression (p-value cho AgeOfStore).

IV. Điểm đặc biệt và lưu ý

4.1. Vấn đề đa so sánh

Khi thực hiện đồng thời k = 3 cặp t-test, xác suất phạm lỗi Loại I lên tới ≈ 14.3%, vượt xa mức chấp nhận 5%. Bắt buộc phải hiệu chỉnh bằng Bonferroni ($\alpha^* = 0.05/3 = 0.0167$) hoặc Tukey HSD trước khi kết luận. Không hiệu chỉnh thì tỉ lệ kết luận sai tăng gần 3 lần.

4.2. Promotion 1 vs 3: Chênh lệch không có ý nghĩa thống kê

Dù Promotion 1 có mean cao hơn Promotion 3 (58.10K và 55.36K = 2.74K), sự khác biệt này không có ý nghĩa thống kê ($p = 0.1208 > \alpha = 0.0167$). Kết luận "Promotion 1 là tốt nhất một cách tuyệt đối" là không chính xác về mặt thống kê. OLS Regression cũng xác nhận Promo_3 có coef = -1.07 với p = 0.35.

4.3. sklearn.LinearRegression không cung cấp p-value

Sử dụng sklearn để fit OLS nhưng không có p-value, dẫn đến kết luận thiếu căn cứ thống kê. Cần tính tay bằng công thức $\beta = (X^TX)^{-1}X^Ty$ hoặc dùng thư viện statsmodels để có bảng kết quả đầy đủ.

4.4. Cấu trúc dữ liệu dạng Panel

Mỗi LocationID xuất hiện 4 lần (4 tuần) nên các quan sát trong cùng một cửa hàng có thể tương quan với nhau. OLS chuẩn giả định các quan sát độc lập thì vi phạm giả định này có thể làm sai lệch Standard Errors. Giải pháp đúng đắn hơn là dùng Linear Mixed-Effects Model hoặc Clustered Standard Errors.

4.5. Market Size là biến quan trọng

Market Size ảnh hưởng mạnh đến doanh số (14.07K cho Large, -12.56K cho Medium so với Small) và có thể phân bố không đều giữa các nhóm promotion. Nếu không kiểm soát Market Size trong mô hình, kết quả về promotion có thể bị hủy. OLS Regression xử lý điều này bằng cách thêm Market Size vào mô hình đồng thời.

4.6. Thiếu thông tin về nội dung promotion

Bộ dữ liệu không tiết lộ nội dung cụ thể của từng promotion (giảm giá, combo, quảng cáo). Điều này giới hạn khả năng suy diễn nhân quả và thiết kế lại chiến dịch. Nên thu thập thêm thông tin này để phân tích có giá trị hành động cao hơn.

V. Thực hiện mô hình và kết quả

5.1. Kiểm định ANOVA

Kiểm định One-Way ANOVA nhằm trả lời: "Có ít nhất một cặp promotion nào có doanh số trung bình khác nhau có ý nghĩa thống kê không?"

Bảng 4. Kết quả kiểm định One-Way ANOVA

Thống kê	**Giá trị**	**Kết luận**
F-statistic	21.9535	
p-value	< 0.0001	Bác bỏ H_0 — Có khác biệt
Kết luận		Tồn tại nhiều hơn 1 cặp promotion có doanh số khác nhau đáng kể

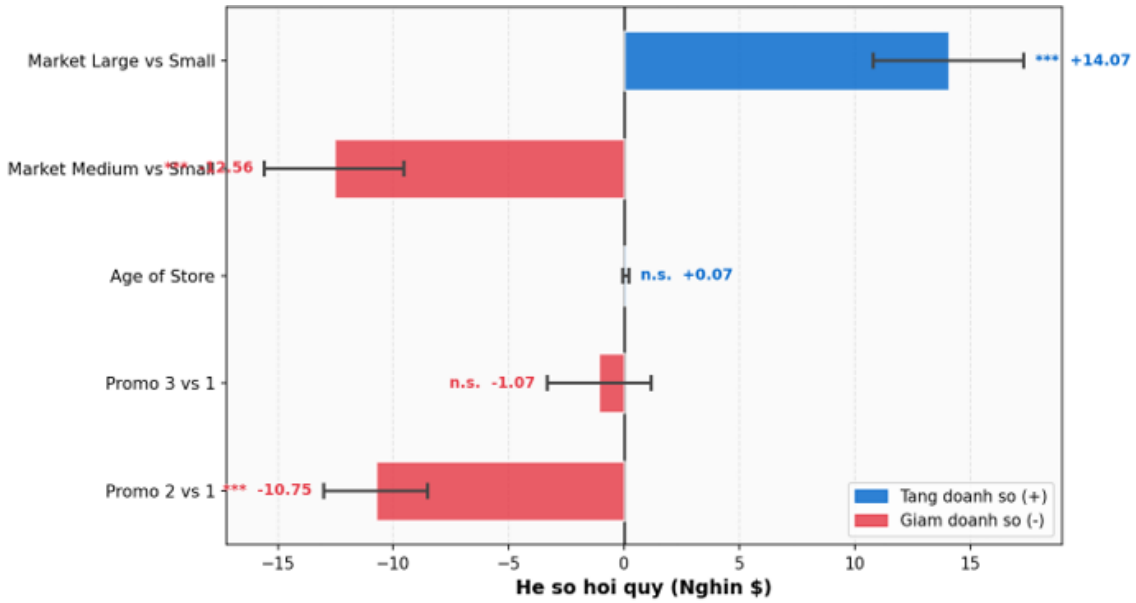
5.2. T-test pairwise với Bonferroni Correction

Bảng 5. T-test pairwise (Bonferroni $\alpha^* = 0.05/3 = 0.0167$)

Cặp so sánh	**t-statistic**	**p-value**	**p < α*?**	**Kết luận**
Promo 1 vs Promo 2	6.454	< 0.0001	Có	Khác biệt rõ
Promo 1 vs Promo 3	1.555	0.1208	Không	Tương đương
Promo 2 vs Promo 3	-4.881	< 0.0001	Có	Khác biệt rõ

Kết luận: Promotion 1 và 3 không khác biệt có ý nghĩa thống kê (p = 0.1208). Promotion 2 kém hơn cả hai nhóm còn lại rõ rệt.

5.3. OLS Regression



Hình 8 - Hệ số OLS Regression với khoảng tin cậy 95%

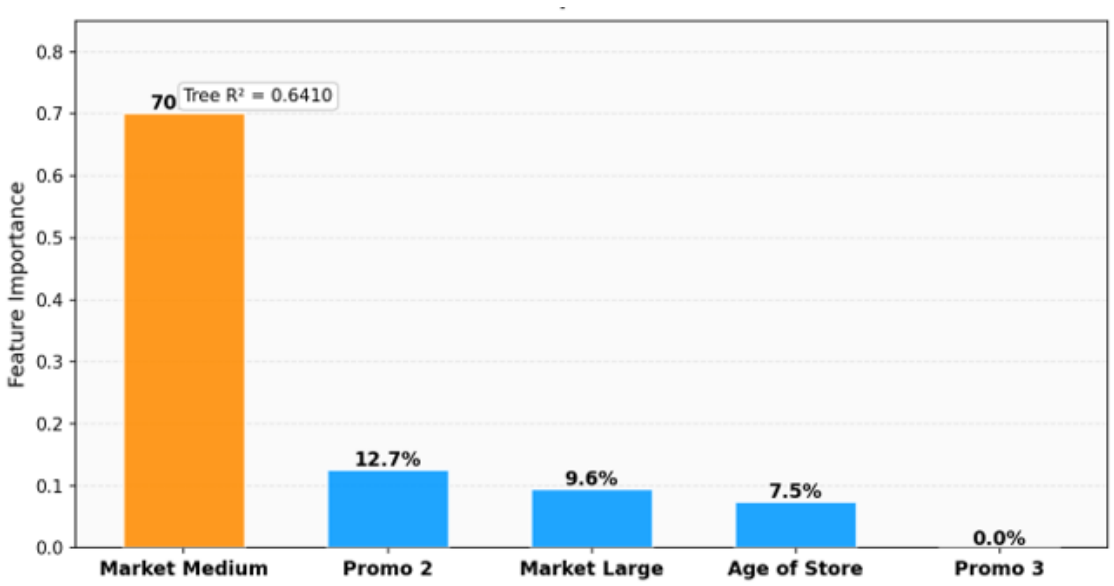
Bảng 6. Kết quả OLS Regression (R^2 = 0.5820, RMSE = 10.88K)

Biến	Coef (K)	Std Err	t-stat	p-value	Ý nghĩa
Intercept (Promo1, Small)	59.94	1.729	34.67	<0.001	***
Promo_2	-10.75	1.149	-9.355	<0.001	***
Promo_3	-1.07	1.152	-0.932	0.352	n.s.
AgeOfStore	0.07	0.071	0.995	0.320	n.s.
Market_Medium	-12.56	1.539	-8.161	<0.001	***
Market_Large	14.07	1.661	8.472	<0.001	***

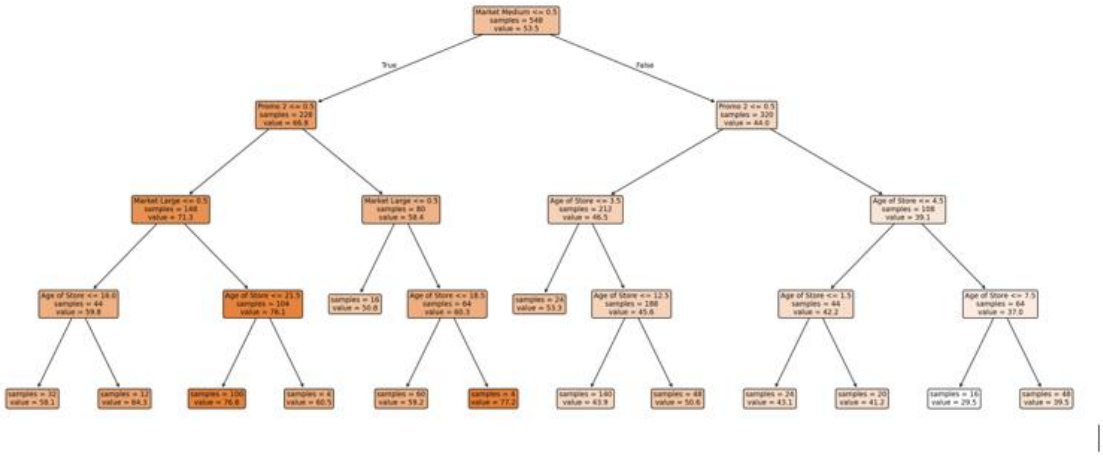
**** p<0.001, n.s. = không có ý nghĩa thống kê*

Diễn giải: Mô hình giải thích được 58.2% biến thiên trong doanh số. Promo_2 làm giảm doanh số 10.75K so với Promo_1 (p<0.001). Promo_3 và AgeOfStore không có ý nghĩa thống kê. Market_Large tăng thêm 14.07K, Market_Medium giảm 12.56K so với Small.

5.4. Decision Tree



Hình 9 - Feature Importance của Decision Tree



Hình 10 - Cây quyết định hoàn chỉnh (max_depth=4)

Nhận xét: Decision Tree ($R^2 = 0.641$) cao hơn OLS (0.582) do nắm bắt được tương tác phi tuyến. Nút gốc là Market_Medium - xác nhận Market Size là yếu tố phân khúc chính. Promo_3 có Feature Importance = 0% — hoàn toàn nhất quán với kết quả OLS ($p = 0.35$).

VI. Kết luận và khuyến nghị

6.1. Trả lời câu hỏi nghiên cứu

Promotion nào hiệu quả nhất? Promotion 1 với doanh số 58.10K/tuần, được xác nhận nhất quán bởi cả ba phương pháp. Tuy nhiên cần phân biệt:

Promo 1 vs Promo 2: Chênh lệch 10.75K - có ý nghĩa thống kê rất cao ($p < 0.001$). Đây là bằng chứng chắc chắn.

Promo 1 vs Promo 3: Chênh lệch 2.74K - không có ý nghĩa thống kê ($p = 0.12$). Hai promotion này tương đương nhau về mặt thống kê.

Bảng 7. Tổng hợp bằng chứng từ ba phương pháp

Phương pháp	**Promo 1 vs Promo 2**	**Promo 1 vs Promo 3**
ANOVA/T-test	p<0.001, có ý nghĩa ***	p=0.121, không có ý nghĩa
OLS Regression	Coef=-10.75, p<0.001 ***	Coef=-1.07, p=0.35.
Decision Tree	Promo_2 Importance = 12.7%	Promo_3 Importance = 0.0%
Kết luận chung	Promo 1 chắc chắn hơn Promo 2	Promo 1 tương đương Promo 3

6.2. Khuyến nghị

Loại bỏ Promotion 2 ngay lập tức: Thua kém ở mọi phân khúc thị trường, kém Promo 1 tới 22.7%. Bằng chứng thống kê nhất quán từ cả ba phương pháp. Triển khai Promotion 1 cho thị trường Small và Medium: Lựa chọn an toàn và được xác nhận tốt nhất bởi dữ liệu. Cân nhắc Promotion 3 cho thị trường Large: Tại Large Market, Promo 3 đạt 77.20K so với 75.24K của Promo 1. Nếu chi phí Promo 3 thấp hơn, đây là lựa chọn tiết kiệm chi phí hơn. Ưu tiên phân bổ ngân sách cho Large Market: Market_Large tăng 14.07K doanh số, đây là cơ hội lớn nhất để tối đa hóa ROI. Không cần phân biệt promotion theo tuổi cửa hàng: AgeOfStore không có ý nghĩa thống kê - chiến lược marketing không cần điều chỉnh theo tiêu chí này.

6.3. Hạn chế và hướng nghiên cứu tiếp theo

Thu thập thông tin về nội dung cụ thể của từng promotion để phân tích nhân quả sâu hơn. Mở rộng thời gian quan sát để đánh giá hiệu quả dài hạn và khả năng giữ chân khách hàng. Áp dụng Linear Mixed-Effects Model để kiểm soát đúng cấu trúc panel data. Bổ sung phân tích chi phí - hiệu quả khi có dữ liệu về chi phí triển khai từng promotion. Thử nghiệm Random Forest hoặc Gradient Boosting để cải thiện dự báo và Feature Importance ổn định.